Ejercicio 01 · Dataset público y SVM reproducible

INF-8239 Ciencia de Datos II (UASD) · Unidad 01 · Integración de LAB01 y LAB02

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad01-01
Fecha de ejecución	2026-11-02

1. Identificación del dataset (LAB02)

Adult (Census Income) · UCI Machine Learning Repository · licencia **CC BY 4.0** · URL `https://archive.ics.uci.edu/static/public/2/adult.zip` · ficha `https://archive.ics.uci.edu/dataset/2/adult`.
48,842 filas x 15 columnas; partición estratificada 80/20 con semilla 42 (39,073 entrenamiento / 9,769 prueba). Target **income** (<=50K / >50K, 23,93 % positivos). SHA-256 de los bytes descargados: `7537312dd56c2b98035880805ce99e68183a30ee468aa5329d6df0fbb3cc21bb`.
Variables usadas: age, workclass, education, education_num, marital_status, occupation, relationship, capital_gain, capital_loss, hours_per_week. Columnas excluidas por motivo semántico y de equidad: fnlwgt, race, sex, native_country. El candidato alterno evaluado fue *Bank Marketing* (UCI, CC BY 4.0), que exige excluir *duration* por fuga de información. La ficha comparativa completa está en `docs/ficha_dataset.md`.
LAB01 usa el dataset de diagnóstico de mama de Wisconsin incluido en scikit-learn (569 muestras, 30 variables, 2 clases).

2. Tabla principal de resultados

Laboratorio	Modelo	Accuracy	F1 macro	Recall
LAB01 · Wisconsin	DummyClassifier (baseline)	0.6316	0.3871	0.0000
LAB01 · Wisconsin	SVC rbf, C=10 gamma=0.01	0.9825	0.9812	0.9762
LAB02 · Adult	DummyClassifier (mismo preprocesamiento)	0.7607	0.4320	0.0000
LAB02 · Adult	SVC rbf con pipeline, C=10 gamma=0.1	0.8588	0.7928	0.6146

Recall de la clase costosa: en LAB01 la clase maligno (0 = maligno); en LAB02 la clase **>50K**. F1 macro de validación: 0,9739 (LAB01, 5 folds) y 0,7759 (LAB02, submuestra estratificada del 25 %; el mejor modelo se reajustó sobre las 39.073 filas de entrenamiento). LAB02 deja fuera 901 de 2,338 casos que superan el umbral de ingreso.

3. Figuras

Figura 1. LAB01 · matriz de confusión del SVM sobre el conjunto de prueba.

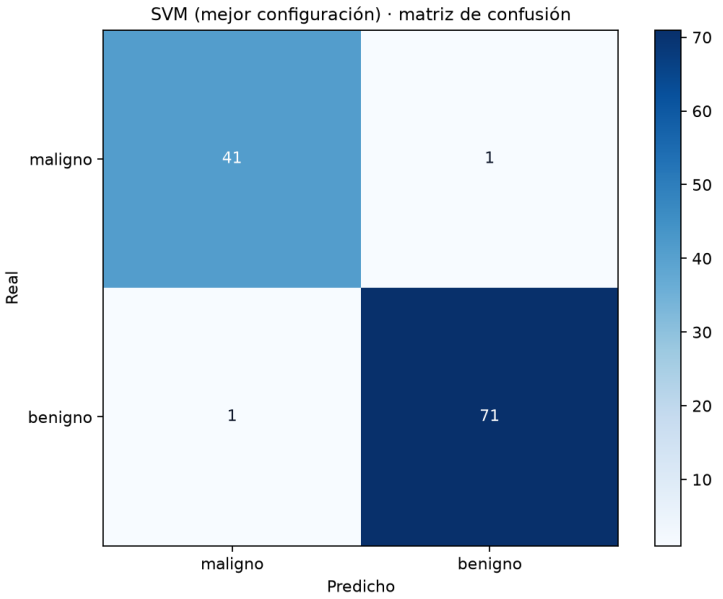
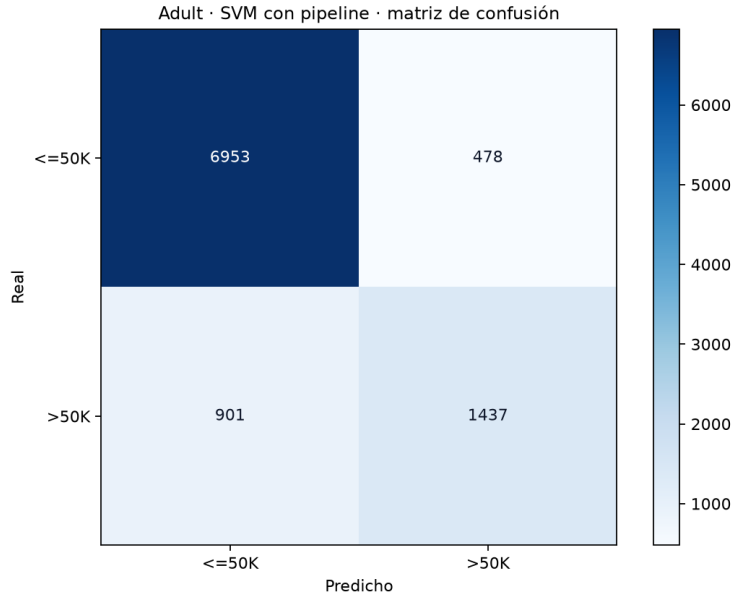


Figura 2. LAB02 · matriz de confusión del SVM con pipeline sobre el conjunto de prueba.



4. Conclusión

Qué se construyó. Dos experimentos reproducibles con el mismo esqueleto de proyecto: un pipeline de SVM con estandarización dentro del `Pipeline` sobre el dataset de diagnóstico de mama de Wisconsin (LAB01), y un pipeline completo con `ColumnTransformer` (imputación + escala para variables numéricas, imputación + codificación one-hot para categóricas) sobre el dataset público **Adult (Census Income)** de UCI (LAB02), elegido tras comparar dos candidatos verificados y documentado en `docs/ficha_dataset.md`.

Resultados. En LAB01 el baseline `DummyClassifier` alcanza 0,6316 de exactitud y 0,3871 de F1 macro (recall 0 para la clase maligno, porque predice siempre la mayoritaria) y el SVM con `C=10, gamma=0.01` llega a **0,9825 de exactitud y 0,9812 de F1 macro** en la prueba, con un único falso negativo sobre 42 casos malignos (recall 0,9762). En LAB02, sobre 48.842 registros de Adult, el baseline marca 0,7607 de exactitud con recall 0,0000 para la clase `>50K` y el SVM llega a **0,8588 de exactitud, 0,7928 de F1 macro y 0,6146 de recall** para `>50K`.

Lectura crítica. El contraste entre ambos resultados es la lección principal. En LAB01 el desempeño muy alto es coherente con un benchmark didáctico y bien estructurado; en LAB02 el mismo tipo de modelo deja fuera a **901 de 2.338 personas** que superan el umbral de ingreso. La causa no está en el algoritmo: `capital_gain` es cero en el 91,74 % de las filas y solo el 21,3 % de los casos `>50K` lo tienen positivo, de modo que la variable que más distingue los ingresos altos falta en cuatro de cada cinco casos positivos. A eso se suman 52 filas duplicadas, un censo de 1994–1996 sin contexto temporal y una población que no cubre a menores ni a personas sin ingresos declarados. Los 20 errores revisados, con semilla fija, confirman el patrón: los falsos negativos son personas con estudios superiores y `capital_gain` = 0 cuyo perfil no aparece en los ejemplos positivos.

Decisión. Ambos pipelines se entregan como líneas base auditables, no como herramientas de decisión sobre personas. El siguiente experimento es medir el desempeño por grupo sin usar los atributos sensibles excluidos (`race`, `sex`, `native_country`), contrastar con un modelo capaz de representar la dispersión de `capital_gain` y repetir el análisis sobre una cohorte más reciente.

Estado pendiente: la aprobación del docente sobre el dataset del LAB02 sigue sin recibirse. El manual de la Unidad 01 prohíbe continuar con el entrenamiento final sin ella; el entrenamiento se ejecutó con la aprobación pendiente y así queda registrado en `reports/dataset_svm_metrics.json` (`aprobacion_docente: pendiente`). Los resultados de LAB02 corresponden a un censo de 1994-1996 de la población activa estadounidense: no son extrapolables y no autorizan decisiones sobre personas.