Ejercicio 02 · Ensambles, reducción dimensional y Green AI

INF-8239 Ciencia de Datos II (UASD) · Unidad 01 · Integración de LAB03 · Código U01.E02

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad01-02
Dataset (Ejercicio 01)	Adult (Census Income) · UCI · CC BY 4.0
Fecha de ejecución	2026-11-05

1. Identificación del dataset y protocolo

Adult (Census Income) · UCI Machine Learning Repository · licencia **CC BY 4.0** · `https://archive.ics.uci.edu/static/public/2/adult.zip`.
Target **income** (<=50K / >50K). Se conservan **dataset, target y partición estratificada 80/20 con semilla 42 del Ejercicio 01**: mismo preprocesamiento (imputación, estandarización y one-hot dentro del pipeline) y mismo conjunto de prueba de 9.769 casos. Exclusiones semánticas: `fnlwgt, race, sex, native_country`.

2. Tabla principal de resultados

Configuración	Familia	F1 macro	Accuracy	Ajuste (s)	Inferencia (ms)	Tamaño (KB)	Pareto
boost	Boosting	0,8185	0,8753	0,59	16,8	360	sí
svm_c10	SVM (C=10)	0,7926	0,8585	40,97	5.211,1	5.980	
svm_c10_pca	SVM (C=10) + PCA	0,7888	0,8580	31,85	4.316,3	2.279	
svm_c1	SVM (C=1)	0,7876	0,8576	27,84	5.216,6	6.002	
rf_300	Random Forest 300	0,7834	0,8480	0,97	228,7	296.866	
rf_100	Random Forest 100	0,7823	0,8469	0,42	78,7	98.807	sí
logreg	Logística	0,7792	0,8507	1,33	18,0	4	
logreg_pca	Logística + PCA	0,7749	0,8485	0,47	28,9	14	

Tiempos y tamaños: mediana de **3 repeticiones** de ajuste y de inferencia, y tamaño del pipeline serializado. Configuración elegida en la frontera de Pareto: **boost** (F1 macro 0,8185). Diferencia absoluta frente a la mejor utilidad: 0,00 de F1 macro; ahorro de tiempo: 0,0 %; diferencia de tamaño: 0 KB. El SVM infiere 309 veces más lento que el boosting (5.211,1 ms frente a 16,8 ms) y el recall de **>50K** va de 0,5778 (`logreg_pca`) a 0,6600 (`boost`). Entorno: Python 3.12.15, scikit-learn 1.9.1, x86_64, Linux-6.12.113+deb13-amd64-x86_64-with-glibc2.41.

3. Figuras

Figura 1. Frontera de Pareto: F1 macro frente a tiempo de ajuste (mediana de 3 repeticiones) y frente al tamaño del modelo (`reports/pareto.png`).

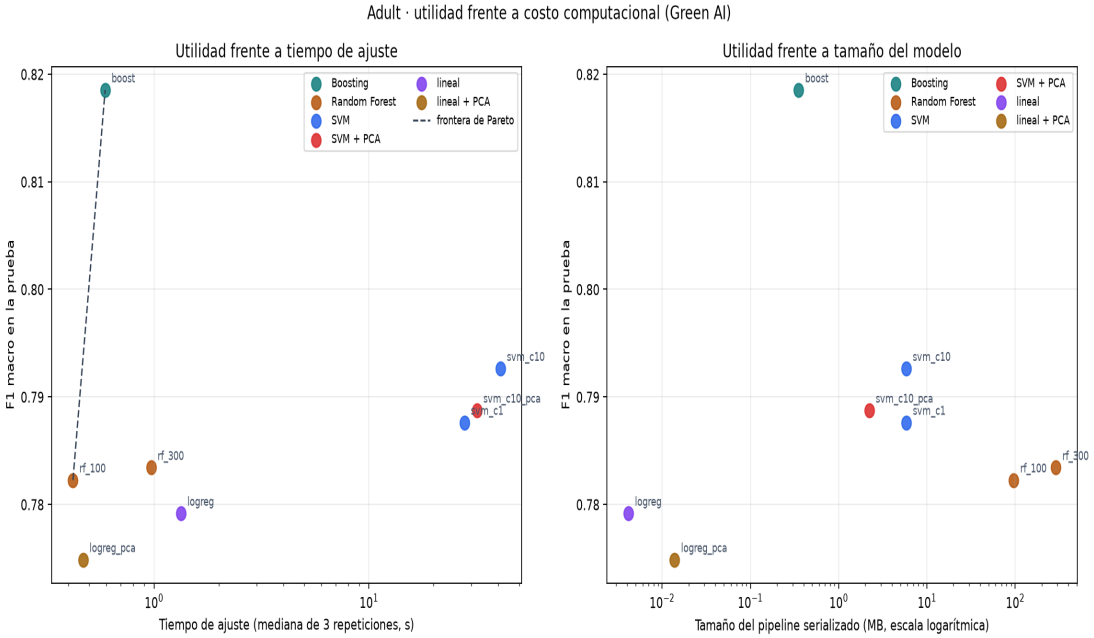


Figura 2. PCA: espectro de varianza y proyección 2D del conjunto de prueba (`reports/pca_analysis.png`); hacen falta 19 componentes para el 90 % de la varianza y 26 para el 95 %.

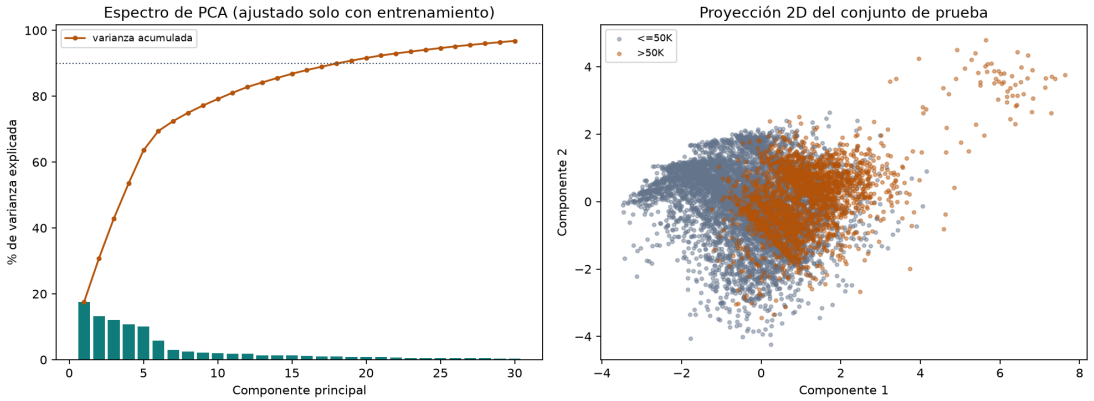


Figura 3. Dos mapas t-SNE sobre 6.000 casos de prueba con submuestra **uniforme** (no estratificada), con semillas 42 y 7 (`reports/tsne_two_seeds.png`).

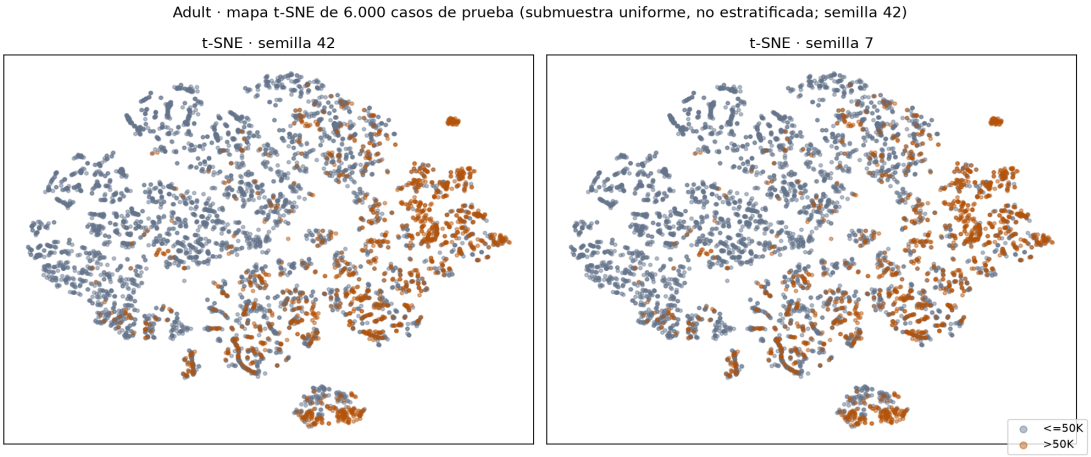
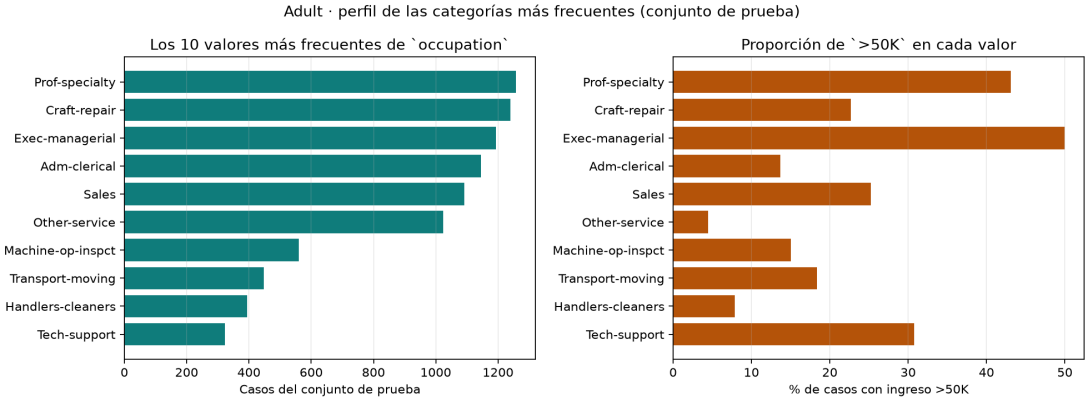


Figura 4. Perfil de las diez categorías más frecuentes de `occupation` y proporción de **>50K** en cada una (`reports/popular_top10.png`).



4. Conclusión

Qué se comparó. Ocho configuraciones homogéneas sobre el dataset, el target y la partición aprobados en el Ejercicio 01 (Adult / Census Income, UCI, CC BY 4.0; target `income`; partición estratificada 80/20 con semilla 42; 9.769 casos de prueba): regresión logística, SVM con `C=1` y `C=10`, Random Forest de 100 y 300 árboles, boosting (`HistGradientBoosting`) y dos variantes con reducción por PCA de 20 componentes. Cada configuración se ajustó **tres veces** y se reporta la **mediana** del tiempo de ajuste y de la inferencia, más el tamaño del pipeline serializado.

Resultado. El F1 macro va de 0,7749 (`logreg_pca`) a **0,8185 (`boost`)**. El boosting gana con 0,59 s de ajuste, 360 KB de modelo y 16,8 ms de inferencia: es simultáneamente la mejor utilidad y una de las opciones más baratas, por lo que la diferencia absoluta de F1 macro frente a la mejor configuración es 0,00. Frente a la otra configuración no dominada (`rf_100`, 0,7823) gana 0,0363 de F1 macro con un tiempo de ajuste de 0,59 s frente a 0,42 s de `rf_100` y **96,1 MB menos de modelo**. El SVM, en cambio, infiere **309 veces más lento** (5.211,1 ms frente a 16,8 ms para las mismas 9.769 filas) y el Random Forest de 300 árboles ocupa **289,9 MB** para peor desempeño. El PCA reduce el costo del SVM (31,85 s y 2,2 MB frente a 40,97 s y 5,8 MB) pero **resta** 0,0039 de F1 macro: el 90 % de varianza que retiene no incluye la señal que separa los ingresos altos. Los dos mapas t-SNE (semillas 42 y 7) conservan los mismos agrupamientos aunque cambian las coordenadas: la estructura persiste, la representación no.

Decisión y defensa. Se entrega `boost`: máxima utilidad y costo entre los más bajos. El tiempo de ajuste y el tamaño del modelo son **proxies contextuales de costo, no consumo energético**; las cifras solo valen en el hardware registrado (Python 3.12.15, scikit-learn 1.9.1, x86_64, Linux). La limitación de fondo es la del Ejercicio 01: `capital_gain` está ausente en el 91,74 % de las filas y el recall de `>50K` va de 0,5778 (`logreg_pca`) a 0,6600 (`boost`): ninguna frontera de Pareto arregla un problema de datos. La submuestra de t-SNE es **uniforme**, no estratificada, de modo que puede desbalancear las clases (23,07 % de `>50K` frente a 23,93 % de la prueba).

Pendiente crítico: la aprobación del docente sobre el dataset sigue sin recibirse (arrastrada del Ejercicio 01) y este ejercicio se ejecutó con esa aprobación pendiente, tal como consta en `reports/green_ai_decision.json`.

5. Referencias

Becker, B. y Kohavi, R. (1996). *Adult* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5XW20

Dodge, J., Schwartz, R., Strubell, E., et al. (2022). *A Green AI*. arXiv:2211.05859. https://arxiv.org/abs/2211.05859

Strubell, E., Ganesh, A. y McCallum, A. (2019). Energy and Policy Considerations for Deep Learning in NLP. En *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (págs. 4135-4148). Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1423

Universidad Autónoma de Santo Domingo (UASD). (2026). *Manual de la Unidad 01: modelos de aprendizaje automático, ensembles y Green AI*. INF-8239 Ciencia de Datos II, Prof. Edwin Ramón José Nolasco.

scikit-learn. (2026). *Documentación de scikit-learn 1.9*: SVC (https://scikit-learn.org/stable/modules/svm.html) y `TfidfVectorizer` (https://scikit-learn.org/stable/modules/feature_extraction.html#text-vectorizer).

Estado pendiente y alcance. La aprobación del docente sobre el dataset sigue pendiente, tal como se detalla en el último párrafo de la conclusión. El dataset es un censo de 1994–1996 de la población activa estadounidense: los resultados no son extrapolables a la población actual y no autorizan decisiones sobre personas. Los tiempos de ajuste y de inferencia y el tamaño de los pipelines son **proxies contextuales de costo** medidos en esta máquina: en otro hardware cambian, y la cifra vigente está siempre en `reports/green_ai_results.csv` y `reports/green_ai_decision.json`.