Ejercicio 02 · Ensambles, reducción dimensional y Green AI

INF-8239 Ciencia de Datos II (UASD) · Unidad 01 · Integración de LAB03 · Código U01.E02

Estudiante	PENDIENTE: nombre completo y matrícula
Correo institucional	PENDIENTE: ID+USUARIO@users.noreply.github.com
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad01-02
Dataset (Ejercicio 01)	Adult (Census Income) · UCI · CC BY 4.0
Fecha de ejecución	2026-11-02

1. Identificación del dataset y protocolo

Adult (Census Income) · UCI Machine Learning Repository · licencia **CC BY 4.0** · `https://archive.ics.uci.edu/static/public/2/adult.zip`.
Target **income** (<=50K / >50K). Se conservan **dataset, target y partición estratificada 80/20 con semilla 42 del Ejercicio 01**: mismo preprocesamiento (imputación, estandarización y one-hot dentro del pipeline) y mismo conjunto de prueba de 9.769 casos. Exclusiones semánticas: `fnlwgt, race, sex, native_country`.

2. Tabla principal de resultados

Configuración	Familia	F1 macro	Accuracy	Ajuste (s)	Inferencia (ms)	Tamaño (KB)	Pareto
boost	Boosting	0.8185	0.8753	0.6	24.4	360	sí
svm_c10	SVM	0.7926	0.8585	43.9	5228.0	5980	
svm_c10_pca	SVM + PCA	0.7888	0.8580	31.3	4304.9	2279	
svm_c1	SVM	0.7876	0.8576	29.6	5250.8	6002	
rf_300	Random Forest	0.7834	0.8480	0.9	145.4	296866	
rf_100	Random Forest	0.7823	0.8469	0.4	89.3	98807	sí
logreg	lineal	0.7792	0.8507	1.9	28.1	4	
logreg_pca	lineal + PCA	0.7749	0.8485	0.6	20.1	14	

Tiempos y tamaños: mediana de **3 repeticiones** de ajuste y de inferencia, y tamaño del pipeline serializado. Configuración elegida en la frontera de Pareto: **boost** (F1 macro 0.8185). Diferencia absoluta frente a la mejor utilidad: 0.0000 de F1 macro; ahorro de tiempo: 0.0 %; diferencia de tamaño: 0 KB. Entorno: Python 3.12.15, scikit-learn 1.9.1, x86_64, Linux-6.12.113+deb13-amd64-x86_64-with-glibc2.41.

3. Figuras

Figura 1. Frontera de Pareto: F1 macro frente a tiempo de ajuste (mediana de 3 repeticiones).

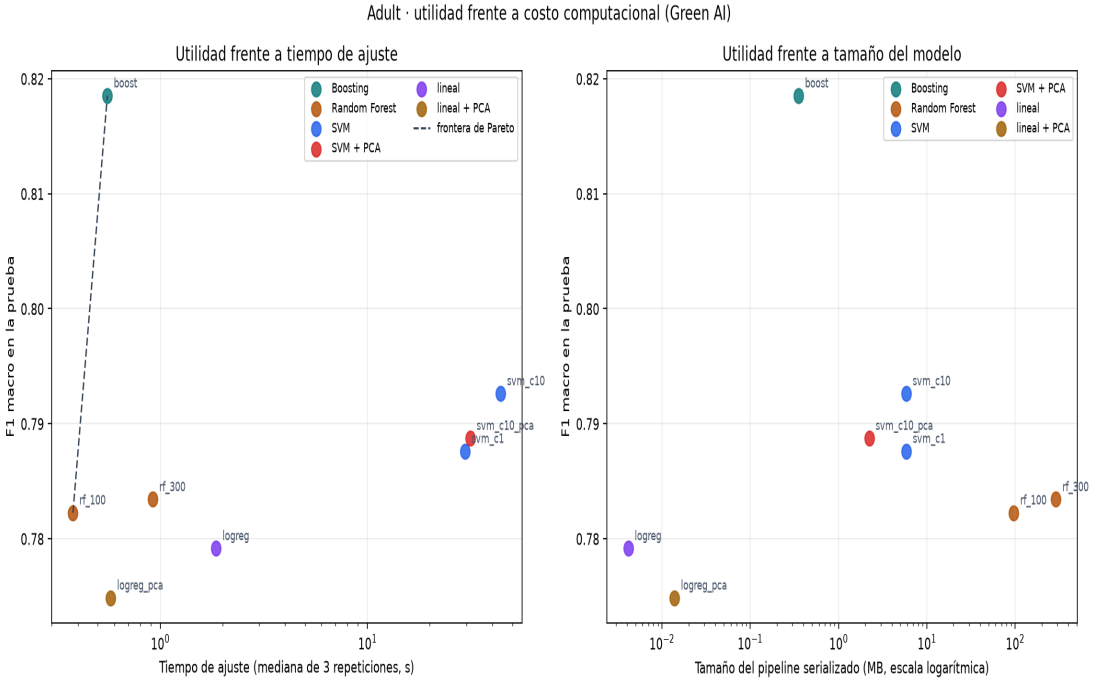


Figura 2. PCA: espectro de varianza y proyección 2D del conjunto de prueba.

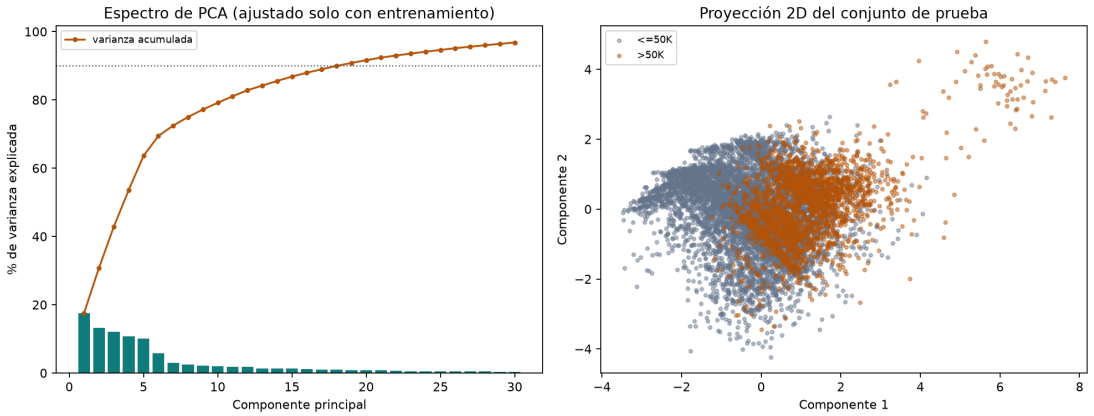
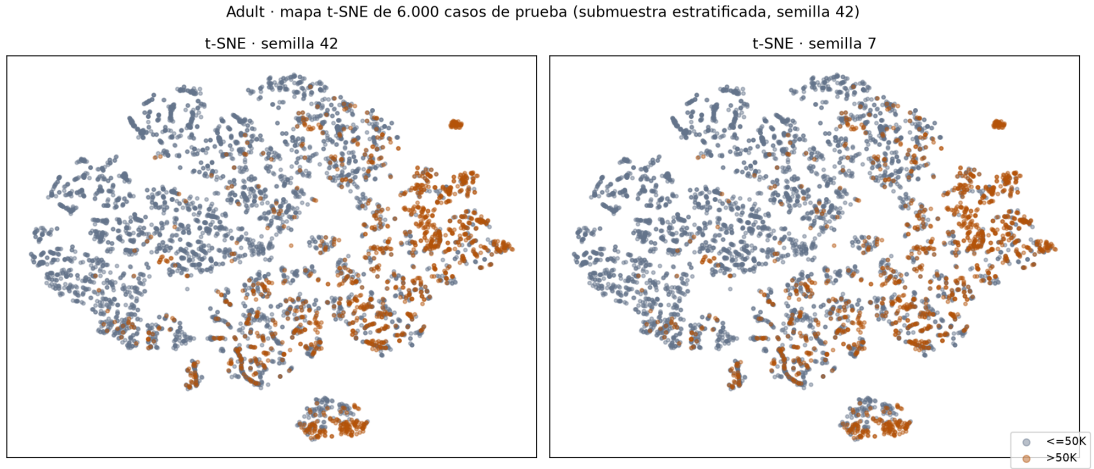


Figura 3. Dos mapas t-SNE sobre 6.000 casos de prueba, con semillas 42 y 7.



4. Conclusión

Qué se comparó. Ocho configuraciones homogéneas sobre el dataset, el target y la partición aprobados en el Ejercicio 01 (Adult / Census Income, UCI, CC BY 4.0; target `income`; partición estratificada 80/20 con semilla 42; 9.769 casos de prueba): regresión logística, SVM con `C=1` y `C=10`, Random Forest de 100 y 300 árboles, boosting (`HistGradientBoosting`) y dos variantes con reducción por PCA de 20 componentes. Cada configuración se ajustó **tres veces** y se reporta la **mediana** del tiempo de ajuste y de la inferencia, más el tamaño del pipeline serializado.

Resultado. El F1 macro va de 0,7749 (`logreg_pca`) a **0,8185 (`boost`)**. El boosting gana con 0,56 s de ajuste, 360 KB de modelo y 24,4 ms de inferencia: es simultáneamente la mejor utilidad y una de las opciones más baratas, por lo que la diferencia absoluta de F1 macro frente a la mejor configuración es 0,00. Frente a la otra configuración no dominada (`rf_100`, 0,7823) gana 0,0363 de F1 macro con 0,18 s más de ajuste y **98,4 MB menos de modelo**. El SVM, en cambio, infiere **214 veces más lento** (5.228 s frente a 24,4 ms para las mismas 9.769 filas) y el Random Forest de 300 árboles ocupa **296,9 MB** para peor desempeño. El PCA reduce el costo del SVM (31,3 s y 2,3 MB frente a 43,9 s y 6,0 MB) pero **resta** 0,0038 de F1 macro: el 90 % de varianza que retiene no incluye la señal que separa los ingresos altos. Los dos mapas t-SNE (semillas 42 y 7) conservan los mismos agrupamientos aunque cambian las coordenadas: la estructura persiste, la representación no.

Decisión y defensa. Se entrega `boost`: máxima utilidad y costo entre los más bajos. El tiempo de ajuste y el tamaño del modelo son **proxies contextuales de costo, no consumo energético**; las cifras solo valen en el hardware registrado (Python 3.12.15, scikit-learn 1.9.1, x86_64, Linux). La limitación de fondo es la del Ejercicio 01: `capital_gain` está ausente en el 91,74 % de las filas y el recall de `>50K` sigue en 0,66 en todas las configuraciones. Ninguna frontera de Pareto arregla un problema de datos.

Estado pendiente: la aprobación del docente sobre el dataset sigue sin recibirse (arrastrada del Ejercicio 01) y elExercise 02 se ejecutó con esa aprobación pendiente. El tiempo de ajuste y el tamaño del modelo son proxies contextuales de costo, **no** una medición de consumo energético: las cifras solo valen en el hardware registrado. El dataset es un censo de 1994–1996 y el recall de la clase **>50K** sigue siendo el punto débil de todas las configuraciones.