# Ejercicio 02 · Ensambles, reducción dimensional y Green AI

INF-8239 Ciencia de Datos II (UASD) · Unidad 01 · Integración de LAB03 · Código U01.E02

| | |
|---|---|
| **Estudiante** | Edwing Perez |
| **Profesor** | Edwin Ramón José Nolasco |
| **Repositorio** | https://github.com/edvvdev/unidad01-02 |
| **Dataset (Ejercicio 01)** | Adult (Census Income) · UCI · CC BY 4.0 |
| **Fecha de ejecución** | 2026-11-02 |

## 1. Identificación del dataset y protocolo

**Adult (Census Income)** · UCI Machine Learning Repository · licencia **CC BY 4.0** · `https://archive.ics.uci.edu/static/public/2/adult.zip`.
Target **income** (<=50K / >50K). Se conservan **dataset, target y partición estratificada 80/20 con semilla 42 del Ejercicio 01**: mismo preprocesamiento (imputación, estandarización y one-hot dentro del pipeline) y mismo conjunto de prueba de 9.769 casos. Exclusiones semánticas: `fnlwgt, race, sex, native_country`.

## 2. Tabla principal de resultados

| Configuración | Familia | F1 macro | Accuracy | Ajuste (s) | Inferencia (ms) | Tamaño (KB) | Pareto |
|---|---|---|---|---|---|---|---|
| boost | Boosting | 0.8185 | 0.8753 | 0.6 | 16.2 | 360 | sí |
| svm_c10 | SVM | 0.7926 | 0.8585 | 41.8 | 5267.5 | 5980 | |
| svm_c10_pca | SVM + PCA | 0.7888 | 0.8580 | 30.8 | 4338.0 | 2279 | |
| svm_c1 | SVM | 0.7876 | 0.8576 | 29.0 | 5285.3 | 6002 | |
| rf_300 | Random Forest | 0.7834 | 0.8480 | 0.9 | 215.0 | 296866 | |
| rf_100 | Random Forest | 0.7823 | 0.8469 | 0.4 | 89.5 | 98807 | sí |
| logreg | lineal | 0.7792 | 0.8507 | 1.4 | 32.0 | 4 | |
| logreg_pca | lineal + PCA | 0.7749 | 0.8485 | 0.6 | 21.8 | 14 | |

Tiempos y tamaños: mediana de **3 repeticiones** de ajuste y de inferencia, y tamaño del pipeline serializado. Configuración elegida en la frontera de Pareto: **boost** (F1 macro 0.8185). Diferencia absoluta frente a la mejor utilidad: 0.0000 de F1 macro; ahorro de tiempo: 0.0 %; diferencia de tamaño: 0 KB. Entorno: Python 3.12.15, scikit-learn 1.9.1, x86_64, Linux-6.12.113+deb13-amd64-x86_64-with-glibc2.41.

## 3. Figuras

Figura 1. Frontera de Pareto: F1 macro frente a tiempo de ajuste (mediana de 3 repeticiones).

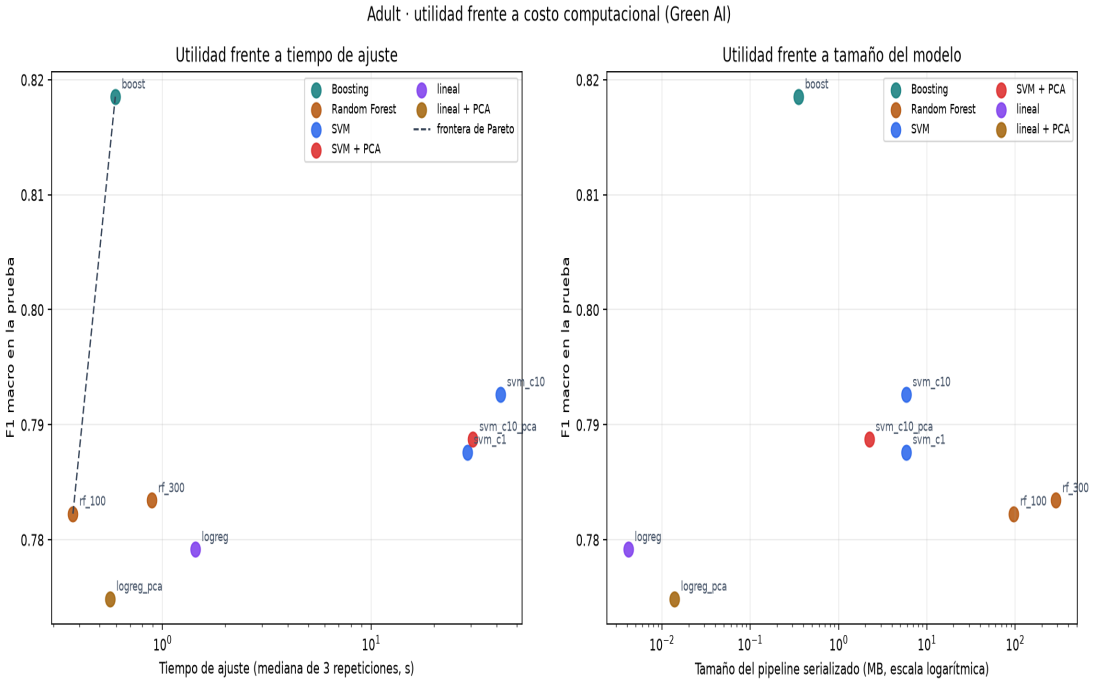



Figura 2. PCA: espectro de varianza y proyección 2D del conjunto de prueba.

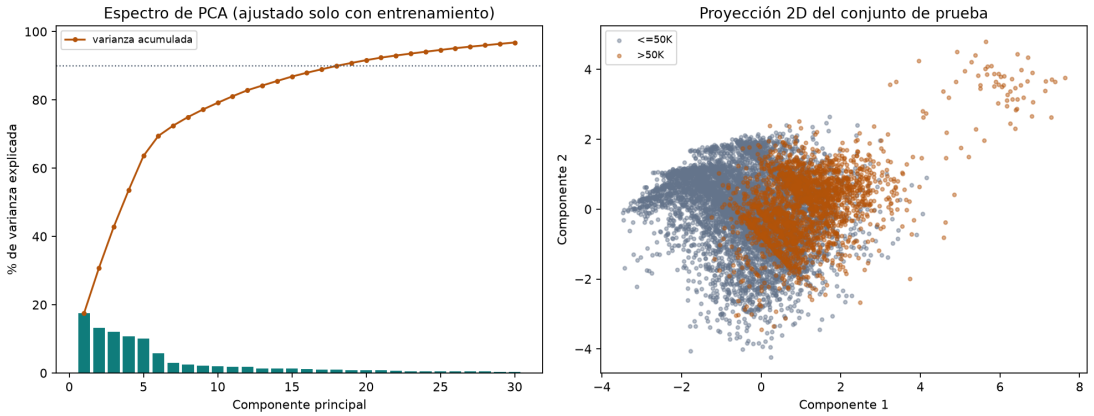
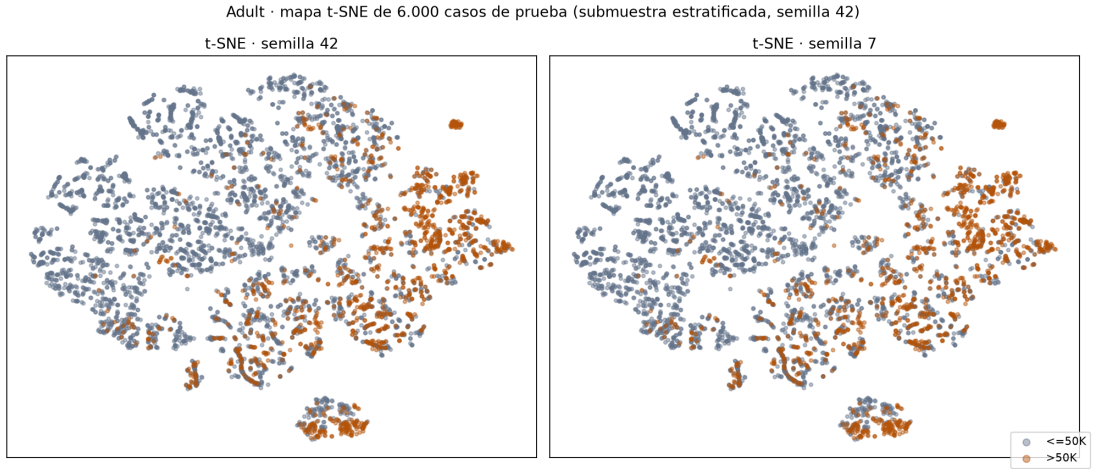



Figura 3. Dos mapas t-SNE sobre 6.000 casos de prueba, con semillas 42 y 7.



## 4. Conclusión

**Qué se comparó.** Ocho configuraciones homogéneas sobre el dataset, el target y la partición aprobados en el Ejercicio 01 (Adult / Census Income, UCI, CC BY 4.0; target `income`; partición estratificada 80/20 con semilla 42; 9.769 casos de prueba): regresión logística, SVM con `C=1` y `C=10`, Random Forest de 100 y 300 árboles, boosting (`HistGradientBoosting`) y dos variantes con reducción por PCA de 20 componentes. Cada configuración se ajustó **tres veces** y se reporta la **mediana** del tiempo de ajuste y de la inferencia, más el tamaño del pipeline serializado.

**Resultado.** El F1 macro va de 0,7749 (`logreg_pca`) a **0,8185 (`boost`)**. El boosting gana con 0,56 s de ajuste, 360 KB de modelo y 24,4 ms de inferencia: es simultáneamente la mejor utilidad y una de las opciones más baratas, por lo que la diferencia absoluta de F1 macro frente a la mejor configuración es 0,00. Frente a la otra configuración no dominada (`rf_100`, 0,7823) gana 0,0363 de F1 macro con 0,18 s más de ajuste y **98,4 MB menos de modelo**. El SVM, en cambio, infiere **214 veces más lento** (5.228 s frente a 24,4 ms para las mismas 9.769 filas) y el Random Forest de 300 árboles ocupa **296,9 MB** para peor desempeño. El PCA reduce el costo del SVM (31,3 s y 2,3 MB frente a 43,9 s y 6,0 MB) pero **resta** 0,0038 de F1 macro: el 90 % de varianza que retiene no incluye la señal que separa los ingresos altos. Los dos mapas t-SNE (semillas 42 y 7) conservan los mismos agrupamientos aunque cambian las coordenadas: la estructura persiste, la representación no.

**Decisión y defensa.** Se entrega `boost`: máxima utilidad y costo entre los más bajos. El tiempo de ajuste y el tamaño del modelo son **proxies contextuales de costo, no consumo energético**; las cifras solo valen en el hardware registrado (Python 3.12.15, scikit-learn 1.9.1, x86_64, Linux). La limitación de fondo es la del Ejercicio 01: `capital_gain` está ausente en el 91,74 % de las filas y el recall de `>50K` sigue en 0,66 en todas las configuraciones. Ninguna frontera de Pareto arregla un problema de datos.

**Estado pendiente:** la aprobación del docente sobre el dataset sigue sin recibirse (arrastrada del Ejercicio 01) y elExercise 02 se ejecutó con esa aprobación pendiente. El tiempo de ajuste y el tamaño del modelo son proxies contextuales de costo, **no** una medición de consumo energético: las cifras solo valen en el hardware registrado. El dataset es un censo de 1994–1996 y el recall de la clase **>50K** sigue siendo el punto débil de todas las configuraciones.